

Previsão e Otimização do Consumo Energético de um Soprador Industrial



Integrantes:

- Lucas Magliari da Purificação Pereira
- Matheus Esteves Pereira Affonso
- Leonardo Bastos Yuan Gouvea
- Dione Lucas Souza da Costa

Índices

<u>Repositório do GitHub</u>	3
<u>Introdução</u>	3
<u>Cronograma</u>	3
<u>Motivações e Justificativas</u>	4
<u>Objetivo</u>	4
<u>Descrição da Base de Dados</u>	5
<u>Referencial Teórico</u>	5
<u>Pipeline da Solução</u>	6
<u>Análise Exploratória e Pré-Processamento dos Dados</u>	7
<u>Modelo</u>	10
<u>Conclusão</u>	11
<u>Link dos Vídeos</u>	12
<u>Referências</u>	13

Repositório do GitHub: <https://github.com/matesteves/projetoaplicado4>

Introdução

O uso eficiente de energia elétrica em ambientes industriais é um tema de crescente relevância, tanto do ponto de vista econômico quanto ambiental. Máquinas como sopradores industriais (blowers) consomem quantidades significativas de energia, podendo impactar negativamente a rentabilidade e a sustentabilidade das operações. Nesse contexto, a análise de séries temporais aliada a técnicas de aprendizado de máquina surge como uma ferramenta promissora para aprimorar o monitoramento e a previsão do consumo energético, apoiando a tomada de decisão e promovendo a eficiência operacional.

A presente pesquisa insere-se na área de eficiência energética industrial e análise de dados, com o intuito de desenvolver um modelo preditivo para o consumo de energia de um soprador elétrico. Com base em dados coletados por um dispositivo de Internet das Coisas (IoT) em intervalos de aproximadamente 10 a 15 minutos, busca-se identificar padrões de consumo, prever demandas futuras e detectar anomalias, contribuindo, assim, para a redução de custos, melhoria da eficiência e atendimento a metas globais de sustentabilidade.

Cronograma

Atividade	Entrega
Coleta e Pré-Processamento dos Dados	09/12/2024
Análise Exploratória e Visualização	09/12/2024
Verificação de Estacionaridade	09/12/2024
Ajuste e Seleção de Modelos (ARIMA/SARIMA.)	09/12/2024
Geração da Previsão e Avaliação Final	09/12/2024
Redação do Relatório Final	09/12/2024

Motivações e Justificativas

A importância do tema decorre de fatores multidimensionais:

1. **Econômico:** A redução do consumo energético pode levar a uma significativa diminuição de custos operacionais, aumentando a competitividade e a lucratividade da empresa.
2. **Ambiental:** A otimização do uso de energia elétrica tem impacto direto na redução de emissões de gases de efeito estufa, contribuindo para o enfrentamento das mudanças climáticas.
3. **Alinhamento com ODS:** O projeto contribui para o alcance do Objetivo de Desenvolvimento Sustentável (ODS) 7 – “Energia Limpa e Acessível” –, ao propor estratégias de uso racional e otimizado da energia.
4. **Inovação e Competitividade:** A aplicação de métodos de aprendizado de máquina em dados de séries temporais fornece suporte a decisões mais assertivas, tornando as operações industriais mais ágeis, flexíveis e resilientes.

Assim, a motivação para este projeto reside na oportunidade de utilizar dados reais e atuais, combinando tecnologias de IoT, análise de dados e algoritmos de aprendizado de máquina para fornecer subsídios práticos ao setor industrial, contribuindo para a eficiência energética e para a sustentabilidade ambiental.

Objetivo

O objetivo geral deste projeto é desenvolver um modelo de previsão do consumo energético de um soprador industrial, a partir de dados históricos, utilizando técnicas de aprendizado de máquina. Os objetivos específicos incluem:

- **Previsão de Consumo:** Estimar a demanda energética do soprador em horizontes curtos de tempo (minutos a horas), permitindo planejamento e ajustes operacionais.
- **Detecção de Anomalias:** Identificar padrões de consumo fora da normalidade, apontando potenciais falhas ou condições subótimas de funcionamento.
- **Otimização Energética:** Fornecer insights que subsidiem a redução do consumo excessivo, promovendo melhor gestão de custos e maior eficiência energética.

- **Disseminação dos Resultados:** Disponibilizar publicamente a metodologia, o código e os resultados obtidos, contribuindo para a comunidade interessada e reforçando o caráter extensionista da iniciativa, alinhado aos ODS.

Descrição da Base de Dados

A base de dados utilizada no presente estudo consiste em medições de consumo energético de um soprador industrial, coletadas por um dispositivo IoT, em intervalos de aproximadamente 10 a 15 minutos. As principais características da base de dados são as seguintes:

- **Origem dos Dados:** Obtenção própria, a partir de um dispositivo IoT acoplado ao equipamento.
- **Atributos Principais:**
 - **srn:** Identificador sequencial de cada registro de medição.
 - **TxnDate:** Data da medição, no formato dia/mês/ano.
 - **TxnTime:** Horário da medição, no formato hora:minuto:segundo.
 - **Consumption:** Consumo de energia elétrica em kWh entre a última e a presente leitura. Valores nulos ou inferiores a 0,5 kWh indicam que o equipamento permaneceu desligado no intervalo correspondente.
- **Formato do Arquivo:** CSV (Comma-Separated Values), contendo quatro colunas (srn, TxnDate, TxnTime, Consumption).
- **Período de Coleta:** Abrange um conjunto contínuo de medições ao longo de um período definido (por exemplo, diversas semanas ou meses), proporcionando uma série temporal a ser explorada.
- **Frequência de Atualização:** Os dados são coletados periodicamente, com potencial atualização semanal ou conforme a necessidade da aplicação.

Com esta estrutura, os dados apresentam características propícias ao emprego de modelos de previsão em séries temporais, tais como ARIMA, LSTM (Long Short-Term Memory) e outras técnicas de aprendizado de máquina para identificação de padrões e tendências no consumo energético.

Referencial Teórico

A análise e previsão de séries temporais tem sido amplamente empregada em diversos setores, incluindo o industrial, para antecipar padrões de consumo, identificar anomalias e otimizar processos (Hyndman; Athanasopoulos, 2018). No contexto energético, a literatura destaca o uso de modelos estatísticos clássicos, como ARIMA e suas extensões sazonais (SARIMA), pela capacidade de modelar dependências temporais e sazonais de forma explícita (Box; Jenkins; Reinsel, 2008). Além disso, modelos de suavização exponencial e decomposição sazonal são utilizados para isolar tendência, sazonalidade e ruído, auxiliando na compreensão dos componentes intrínsecos à série (Hyndman; Athanasopoulos, 2018).

Paralelamente, abordagens de Aprendizado de Máquina (Machine Learning), tais como LSTM (Long Short-Term Memory), têm ganhado relevância pela habilidade de capturar relações não lineares e complexas entre variáveis temporais (Chollet, 2018). Contudo, a seleção do modelo depende do volume e qualidade dos dados, do horizonte de previsão e dos recursos computacionais disponíveis (Ranganathan et al., 2020).

As soluções propostas na literatura apresentam vantagens e limitações. Modelos estatísticos, embora robustos, exigem a verificação de pressupostos como estacionaridade e podem não capturar adequadamente padrões complexos. Já as abordagens de aprendizado profundo podem gerar previsões mais acuradas, porém demandam maior capacidade de processamento e maior quantidade de dados para o treinamento (Williams, 2018).

No presente trabalho, optou-se inicialmente pela aplicação de técnicas estatísticas clássicas (ARIMA/SARIMA) em função do escopo da análise, da disponibilidade reduzida de dados e da necessidade de interpretabilidade (Hyndman; Athanasopoulos, 2018).

Pipeline da Solução

O pipeline seguido no projeto inclui as seguintes etapas:

1. **Coleta e Pré-Processamento dos Dados:** Leitura do arquivo CSV com medições diárias de consumo energético, conversão de datas, tratamento de valores e agregação por dia.
2. **Análise Exploratória e Visualização:** Cálculo de estatísticas descritivas, plotagem de gráficos de linha e barras, além da aplicação da média móvel para compreender tendências.

3. **Verificação de Estacionaridade e Decomposição:** Teste de Dickey-Fuller, decomposição sazonal e identificação de componentes (tendência, sazonalidade e resíduo).
 4. **Seleção e Ajuste de Modelos:** Ajuste de modelos de suavização exponencial e métodos clássicos (ARIMA, SARIMA), selecionando o melhor modelo com base em métricas de qualidade do ajuste.
 5. **Previsão e Intervalos de Confiança:** Geração da previsão futura e faixas de incerteza.
-

Análise Exploratória e Pré-Processamento dos Dados

A análise exploratória dos dados, conforme implementada no notebook, partiu de um conjunto de medições de consumo energético (em kWh) do soprador industrial, coletadas em intervalos e datas específicas. As etapas iniciais incluíram:

1. **Leitura e Integração dos Dados:**

Os dados foram carregados a partir do arquivo CSV, sendo então convertidos para um índice temporal consolidado por dia. Essa agregação diária reduziu a granularidade, porém tornou a série mais estável e fácil de analisar.


2. **Qualidade dos Dados e Tratamento:**

Durante a análise, verificou-se a ausência de valores nulos no atributo de consumo, o que dispensou técnicas de imputação. Entretanto, observou-se que valores de consumo muito baixos indicam períodos em que a máquina esteve desligada, aspecto já conhecido e incorporado à interpretação dos dados.


3. **Análise Inicial e Visualizações:**

Gráficos de linha foram utilizados para visualizar a série temporal original e suas variações ao longo do período estudado, retratando a evolução do consumo energético ao longo do tempo. Observa-se que a série temporal apresenta variações cíclicas e consistentes, com picos regulares que refletem períodos de maior demanda operacional. Além disso, é possível identificar anomalias pontuais, como valores abruptamente elevados ou reduzidos, que podem estar associados a eventos específicos, como manutenção ou flutuações na carga de trabalho. A análise sugere ainda a existência de uma leve tendência ascendente no consumo em determinados períodos, o que pode indicar aumento da carga

operacional ou desgaste progressivo do equipamento.




Esse gráfico de barras, a distribuição diária do consumo energético é apresentada, destacando a frequência de diferentes níveis de consumo. A análise revela que a maior parte dos valores se concentra em uma faixa estreita, indicando relativa estabilidade no funcionamento do soprador. Contudo, são observados outliers representados por barras que extrapolam significativamente o padrão, sugerindo condições atípicas, como períodos de sobrecarga ou ociosidade. Essa visualização permite identificar possíveis dias críticos e auxilia na formulação de estratégias para a regularização do consumo.




Esse gráfico aplica uma média móvel aos dados, proporciona uma visão mais clara das tendências de longo prazo, suavizando as flutuações bruscas. Ao eliminar ruídos, este gráfico destaca uma tendência de aumento gradual no consumo ao longo do período analisado, o que pode estar relacionado a fatores

como mudanças no regime de operação ou perda de eficiência energética. A escolha de um intervalo de média móvel de sete dias é eficaz para capturar padrões semanais, fornecendo uma base sólida para a projeção de cenários futuros e a implementação de ações corretivas.



4. Estacionaridade e Decomposição da Série:


Foram aplicados testes estatísticos (Dickey-Fuller Aumentado) para verificar a estacionaridade da série, demonstrando a necessidade de transformações como a suavização por médias móveis. A decomposição sazonal evidenciou a existência de tendências e componentes sazonais, auxiliando no entendimento estrutural do consumo energético.



Essas etapas de pré-processamento e análise exploratória formaram a base para o ajuste de modelos de previsão, garantindo que o conjunto de dados estivesse adequadamente formatado e entendido antes da etapa de modelagem.

Modelo


Como modelo, optou-se pela utilização de um modelo ARIMA/SARIMA, considerando o caráter temporal e a eventual sazonalidade dos dados. Por meio da biblioteca **pmdarima**, foi utilizado o método **auto_arima** para buscar automaticamente parâmetros iniciais adequados. O modelo selecionado, conforme relatório do notebook, apresentou ordem (3,0,0) com componente sazonal (1,0,0,7), conforme indicado pelo processo de seleção.



O modelo ARIMA/SARIMA baseia-se no ajuste de parâmetros autorregressivos (AR), médias móveis (MA) e integrações (I), além de incorporar padrões sazonais, quando especificados. Ao trabalhar com um horizonte diário de previsão, e tendo em vista a duração limitada da série analisada, optou-se por um modelo relativamente simples, mas robusto, que pôde capturar parte da dinâmica temporal da série. Mesmo não

sendo o modelo mais complexo disponível, ele se mostra adequado nesta etapa inicial do projeto por oferecer uma visão clara sobre o comportamento do consumo ao longo do tempo e fornecer um ponto de partida para melhorias futuras.

A imagem apresentada abaixo demonstra a previsão de consumo ao longo do tempo, construída com base em um modelo de análise preditiva. Os dados históricos, indicados pela linha azul, abrangem o período até 28 de fevereiro de 2022, enquanto a linha vermelha apresenta as projeções para o intervalo de 1º a 9 de março de 2022. A área sombreada ao redor da linha de previsão representa o intervalo de confiança de 95%, indicando o grau de variabilidade esperado nas projeções. O modelo projeta uma leve oscilação no consumo, com uma pequena queda inicial seguida por uma recuperação gradual, em alinhamento com o padrão observado nos dados históricos. Essa previsão fornece uma base sólida para análise e tomada de decisão em relação ao comportamento esperado do consumo no período analisado.



Conclusão

O desenvolvimento deste projeto proporcionou um entendimento consistente do problema de previsão do consumo energético em um contexto industrial, por meio da análise de séries temporais obtidas de um soprador elétrico. Desde a fase inicial, envolvendo a coleta e o pré-processamento dos dados, até a modelagem base com o uso de um modelo estatístico ARIMA sazonal, foi possível estabelecer um fluxo de trabalho reproduzível e transparente. Cada etapa – da análise exploratória à verificação

da estacionaridade, da decomposição sazonal à geração de previsões com intervalos de confiança – contribuiu para a construção de um conhecimento sólido e para a criação de uma base analítica confiável.

O modelo ARIMA sazonal (SARIMA), ao ser aplicado, demonstrou sua utilidade na captura de parte das dinâmicas inerentes à série, fornecendo uma primeira aproximação do comportamento futuro do consumo. Embora esse modelo base possa ser considerado simples diante da complexidade potencial do problema, ele cumpre um papel importante ao oferecer insights iniciais sobre a demanda energética. Tais insights podem orientar decisões de curto prazo, ajudar no planejamento de manutenção preditiva e, eventualmente, na programação de ajustes operacionais que resultem em maior eficiência do uso de energia.

A partir dessa base, abre-se um leque de oportunidades para o aperfeiçoamento da abordagem. A substituição ou complementação do ARIMA por modelos mais complexos, como LSTM ou Prophet, pode levar a previsões mais acuradas e robustas. Ainda, a incorporação de variáveis exógenas – como condições climáticas, cargas de produção ou características técnicas do maquinário – pode enriquecer a análise, permitindo que as previsões não apenas descrevam padrões passados, mas também respondam a fatores externos que influenciam o consumo.

Além do ganho operacional e financeiro para o setor industrial, o uso racional e eficiente da energia alinha-se aos Objetivos de Desenvolvimento Sustentável (ODS), em especial ao ODS 7, que visa assegurar o acesso confiável, sustentável, moderno e a preço acessível à energia para todas as pessoas. Ao oferecer um caminho metodológico para reduzir custos, otimizar recursos e mitigar impactos ambientais, o presente projeto contribui para a promoção de práticas empresariais mais sustentáveis e para a conscientização sobre a importância da eficiência energética.

Em suma, o projeto fornece uma plataforma de análise inicial, a partir da qual ajustes, refinamentos e novas experimentações podem ser realizados. A conclusão desta etapa não significa o fim, mas o início de um processo contínuo de melhoria e exploração, cujo resultado final poderá desempenhar um papel relevante na transformação de dados em decisões estratégicas e na consolidação de uma cultura empresarial mais eficiente e ambientalmente responsável.

Link do Vídeo de Apresentação do Projeto: <https://youtu.be/KJnu9gn4EoI>

Link do Vídeo de Apresentação da Solução Técnica: <https://youtu.be/31wxoBFTqEo>

Referências

BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C. *Time Series Analysis: Forecasting and Control*. 4. ed. Hoboken: John Wiley & Sons, 2008.

CHOLLET, F. *Deep learning with Python*. Shelter Island: Manning Publications, 2018.

CHOLLET, F. *Deep learning with Python*. Shelter Island: Manning Publications, 2018.

HINDMAN, R. J.; ATHANASOPOULOS, G. *Forecasting: principles and practice*. OTexts, 2018. Disponível em: <https://otexts.com/fpp2/>.

HYNDMAN, R. J.; ATHANASOPOULOS, G. *Forecasting: principles and practice*. 2. ed. OTexts, 2018. Disponível em: <https://otexts.com/fpp2/>.

ORGANIZAÇÃO DAS NAÇÕES UNIDAS (ONU). *Objetivos de Desenvolvimento Sustentável (ODS)*. Disponível em: <https://brasil.un.org/pt-br/sdgs>.

RANGANATHAN, S. et al. *Machine Learning Approaches to Energy Consumption Forecasting in Manufacturing Systems*. IEEE Transactions on Automation Science and Engineering, v. x, n. y, p. z, 2020.

RANGANATHAN, S. et al. *Machine Learning Approaches to Energy Consumption Forecasting in Manufacturing Systems*. IEEE Transactions on Automation Science and Engineering, 2020.

WILLIAMS, G. *Data Science Essentials in Python*. New York: Springer, 2018.

WILLIAMS, G. *Data Science Essentials in Python*. New York: Springer, 2018.